

CU_____

Examen Parcial A:

El examen durará **15 minutos** y valdrá **10 puntos**. No se permite usar apuntes, formularios ni dispositivos electrónicos; solo las hojas del examen, pluma o lápiz y goma (borrador/corrector). Está prohibido copiar o hablar durante el examen y, al finalizar, no se puede hablar ni usar electrónicos. Se puede salir a distraerse; la clase se reanuda a las **19:20**. **No pongas tu nombre solo la CU**

1. (2 pts) Dibuja la jerarquía de memoria de una computadora moderna (desde registros hasta disco). Para cada nivel indica si su velocidad es alta o baja y si su capacidad es grande o pequeña. Incluye GPU

2. (2 pts) ¿En qué se diferencia la filosofía de diseño de un CPU frente a la de un GPU? ¿Qué tipo de tareas resuelve mejor cada uno y por qué?

3. Responde cada inciso (2 pts cada uno)

Necesidad 1: Sistema de búsqueda que recorre un índice de 300 GB en RAM. Queries irregulares (cada una accede a partes diferentes del índice). Requiere baja latencia ($<10\text{ms}$).

Necesidad 2: Servicio de recomendaciones que ejecuta inferencia de una red neuronal. Modelo de 8 GB. 500 requests/segundo.

a) Para la Necesidad 1, ¿qué componente de hardware es el más crítico (CPU, RAM, GPU, disco)? ¿Por qué? ¿Qué tipo de procesador (CPU/GPU/NPU) es más adecuado para este patrón de acceso irregular? Justifica.

b) Para la Necesidad 2, ¿qué tipo de procesador es más adecuado?(CPU, GPU, NPU, TPU, RAM) ¿Por qué?

4. (2pts) ¿Que es el ASL/ensamblador? En que afecta y como está relacionado con los ciclos de reloj.